Wide & Deep Learning for Recommender Systems

By Heng-Tze Cheng et al.


Contents

- 1. Introduction
- 2. Recommender system overview
- 3. Wide & deep learning
- 4. System implementation
- 5. Experiments results
- 6. Implementation
- 7. Related work
- 8. Conclusions


- Memorization
- -feature 또는 item의 빈번한 공존을 학습하고 historical data에서 이용가능한 상관관계를 이용
- -Wide set of cross-product feature transformation 사용
- Generalization
- -correlation의 transitivity에 근거하고 과거에 발생한적이 없는 새로운 feature combination을 탐색하는 것
- -Deep Neural Network 사용

Memorization






Generalization



Generalization + Memorization





exception


Memorization

- 주로 logistic regression(linear model) 사용 확장 가능성, 단순함
- One-hot encoding → binary sparse feature로 학습
- Cross product사용 → feature pair의 공존 표현
- 수동 feature engineering 필요
- 이미 나타난 pair에 대해서만 학습 가능

Generalization

- FM이나 DNN 사용
- Feature data 를 low dim dense embedding vector 로 학습
- →이전에 나타나지 않은 data 예측 가능
- Feature engineering 부하 감소
- Sparse, high rank data인 경우 학습 어려움

- Wide & Deep Learning
 Wide linear model + Deep neural network
- → Memorization + Generalization




Recommender System Overview

• P(y|x)를 기반으로 앱 순위 결정


y: action

x: user features, contextual, impression features

• Wide & Deep 모델 활용



Wide & Deep Learning wide part




$$y = w^T x + b$$

$$\phi_k(\mathbf{x}) = \prod_{i=1}^d x_i^{c_{ki}} \quad c_{ki} \in \{0, 1\}$$

Cross product transformation

- Logistic regression
- 입력:User installed app, Impression app, cross product

Wide & Deep Learning deep part




$$a^{(l+1)} = f(W^{(l)}a^{(l)} + b^{(l)})$$

- Deep Neural Net
- 입력: Continuous and Categorical features

Age, #App Installs, Device Class, Installed app, Impression App 등등


Wide & Deep Learning joint training

- Ensemble이 아닌 두 모델 한번에 back propagation
- Ensemble과 달리 두 모델의 파라미터를 동시에 최적화 가능




• 더 적은 모델 사이즈로 구현 가능, 소수의 cross product로 deep 모델의 약점만 보완

System Implementation




Data Generation



- 일정 기간 동안의 user data와 impression data를 사용해 training data 생성
- Vocabulary를 통해 categorical feature를 integer ID로 매핑

Model training



전체 모델 구조

매번 re-train을 하면 시간 이 오래 걸리기 때문에 warm-starting system으로 학습

warm-starting system - 임베딩과 이전 모형의 선형 모형 가중치를 사용하여 새 모형 초기값을 설정

Model Serving

- 학습된 모델을 모델 서버에 업로드 후 request와 유저 정보에 맞춰 앱 랭킹 출력
- 소규모 batch를 병렬로 실행하여 성능 최적화

Experiments Results

Model	Offline AUC	Online Acquisition Gain
Wide (control)	0.726	0%
Deep	0.722	+2.9%
Wide & Deep	0.728	+3.9%

1% 사용자를 대상으로 테스트한 결과 유의미한 증가가 있었다.

Batch size	Number of Threads	Serving Latency (ms)
200	1	31
100	2	17
50	4	14

배치사이즈에 따른 Serving Latency

Implementation

```
    Dataset: Kaggle Adult income dataset
    15 features(age, workclass, race ...)
    target: find income <=50k or not</li>
    loss function – binary cross entropy
    optimizer – adam
    crossed features for wide model:
    ['education', 'occupation'], ['native_country', 'occupation']
```

Implementation

Epoch 1/10	
509/509 [====================================	acy: 0.7752
Epoch 2/10	_
509/509 [====================================	icy: 0.8218
Epoch 3/10	
509/509 [====================================	icy: 0.8267
Epoch 4/10	
509/509 [====================================	icy: 0.8298
Epoch 5/10	
509/509 [====================================	icy: 0.8314
Epoch 6/10	
509/509 [========================] - 1s 2ms/step - loss: 0.3598 - accura	icy: 0.8330
Epoch 7/10	
509/509 [====================================	icy: 0.8324
Epoch 8/10	
509/509 [==================] - 1s 2ms/step - loss: 0.3569 - accura	icy: 0.8325
Epoch 9/10	
509/509 [==================] - 1s 2ms/step - loss: 0.3559 - accura	icy: 0.8338
Epoch 10/10	
509/509 [========= 0.3552 - accura	
509/509 [==================] - 1s 1ms/step - loss: 0.6571 - accura	юу: 0.6861
wide model accuracy: 0.6860758066177368	

```
Epoch 1/10
                                                    Epoch 1/10
509/509 [================== ] - 3s 3ms/step - loss: 1.4082 - accuracy: 0.7884
                                                    Epoch 2/10
                                                    255/255 [=
                                                     Epoch 4/10
                                                    255/255 [==
                                                    Epoch 8/10
                                                    Epoch 9/10
509/509 [============] - 2s 3ms/step - loss: 0.3886 - accuracy: 0.8359 255/255 [============] - 1s 4ms/step - loss: 0.3412 - accuracy: 0.8510
                                                                      =======] - 1s 4ms/step - Ioss: 0.3377 - accuracy: 0.8513
                       - 2s 3ms/step - loss: 0.3851 - accuracy: 0.8394
                                                    ====] - 1s 2ms/step - loss: 0.9093 - accuracy: 0.7374
                                                    wide and deep model accuracy: 0.7322645783424377
deep model accuracy: 0.7374240159988403
```

Accuracy

Wide: 0.686

Deep: 0.737

Wide & deep: 0.732

Related Work

• Factorization Machine에서 두 변수간 상호작용을 일반화하는 방법

• RNN에서 복잡성을 줄이기 위해 제안된 joint training 활용

• CF 기반과 달리 앱 추천 시스템의 사용자 및 impression data에 대한 wide & deep model을 jointly train

Conclusion

- Wide linear model은 cross-product feature transformations을 사용하여 sparse feature interaction을 효과적으로 memorize할 수 있다
- DNN은 low-dim embedding을 통해 이전에 본적 없는 feature interactions으로 일반화할 수 있다.
- 두 모델의 장점을 결합한 wide & deep learning framework를 제안했고 큰 성능 개선이 있었다.